基于 GRU 的股市预测

组长：苏日清
组员：余思贤，谭铭濠，梁宗威

2021 年 12 月 26 日

目录

课程设计的任务

1. 熟悉 MATLAB 中深度学习工具箱的使用方法，喂入数据的方法，配置训练的方法，保存模型的方法和调用模型的方法；
2. 能画出学习模型的基本框架，理解其基本原理；
3. 基于 GRU 对中国石化的开盘股价进行预测。

课程设计的要求

1. 学会 MATLAB 软件的安装；
2. 熟练掌握 MATLAB 的使用，掌握深度学习工具箱的使用；
3. 能使用深度学习工具箱根据需求搭建神经网络，喂入数据，训练，得出模型并能调用；
4. 通过调参使得模型能更好的贴合实际，打到更好的效果。

目录

序列数据神经网络

循环神经网络（Recurrent Neural Network，RNN）是一种用于处理序列数据的神经网络。相比一般的神经网络来说，他能够处理序列变化的数据。比如某个单词的意思会因为上文提到的内容不同而有不同的含义，RNN 就能够很好地解决这类问题。
一般来说，普通 RNN 网络形式如下：

$$h' = \delta(w_h h + w_i x + b^h) \tag{1}$$

$$y = \delta(w_o h' + b^y) \tag{2}$$

其中 h' 为传入下一节点的参数，y 常使用对 h' 进行唯独映射，然后使用 $softmax$ 进行分类得到所需的参数。

序列数据神经网络

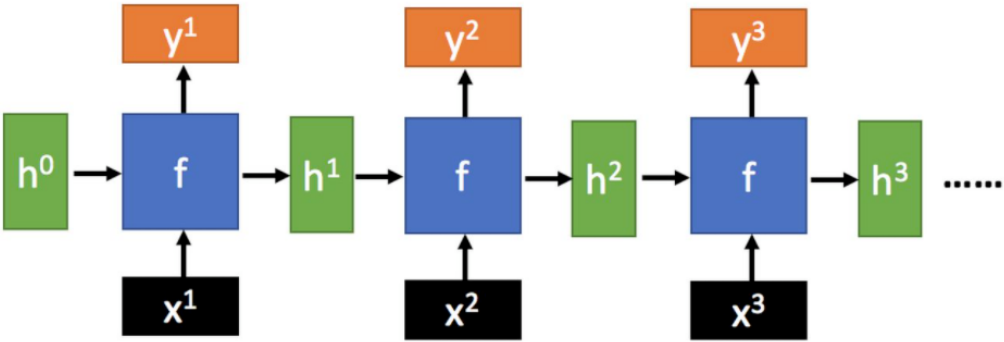

图: 多级 RNN 网络构成

LSTM 结构

长短期记忆（Long short-term memory, LSTM）是一种特殊的 RNN，主要是为了解决长序列训练过程中的梯度消失和梯度爆炸问题。简单来说，就是相比普通的 RNN，LSTM 能够在更长的序列中有更好的表现。LSTM 网络的表达式如下：

$$c^t = z^f \odot c^{t-1} + z^i \odot z \tag{3}$$

$$h^t = z^o \odot \tanh c^t \tag{4}$$

$$y^t = \delta(W' h^t + b^y) \tag{5}$$

其中 c^t 可以理解为长期记忆，主要是用来保存节点传递下来的数据的，每次传递会对某些维度进行“忘记”并且会加入当前节点所包含的内容;，h^t 则为短期记忆，仅保存了先前节点的信息。

LSTM 结构

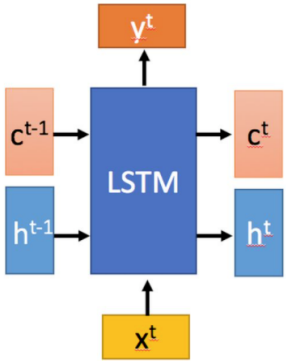

图: LTSM 网络结构

GRU 网络

GRU（Gate Recurrent Unit）是循环神经网络（Recurrent Neural Network, RNN）的一种。和 LSTM（Long-Short Term Memory）一样，也是为了解决长期记忆和反向传播中的梯度等问题而提出来的。
GRU 的输入输出结构与普通的 RNN 是一样的。
其表达式为：

$$r^t = \delta(x^t w^{xr} + h^{t-1} w^{hr} + b^r) \tag{6}$$

$$z^t = \delta(x^t w^{xz} + h^{t-1} w^{hz} + b^z) \tag{7}$$

$$h' = \tanh x^t w^{xr} + r^t \odot h^{t-1} w^{hh} + b^h \tag{8}$$

$$h^t = (1 - z) \odot h' + z \odot h^{t-1} \tag{9}$$

$$y^t = \text{softmax}(h^t w^{hy} + b^y) \tag{10}$$

GRU 网络

GRU 与 LSTM 相比，需要训练的参数较少，但也能达到与 LSTM 相近的效果。其训练的参数少，对硬件要求要求较低，因此本文采用 GRU 进行实现

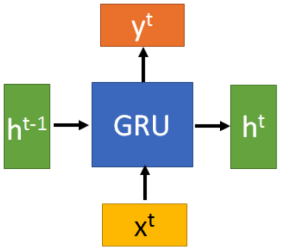

图: GRU 的输入输出结构

目录

数据采集

这里使用 Python 爬取近 16 年中国石化（600028）的股市信息。
代码如下：

```
1 import tushare as ts
2
3 df1 = ts.get_k_data('600028', ktype='D', start='2005-01-01', end='2021-10-16')
4
5 datapath1 = "./SH600028.csv"
6 df1.to_csv(datapath1)
```

得到了 4032 行数据，包括：时间、开盘价格、收市价、高位、低位、成交量以及股票代码。

数据处理

为使得模型更快收敛，并提高其准确性，对取得的数据进行归一化处理，公式如下：

$$x^* = \frac{X - X_{min}}{X_{max} - X_{min}} \tag{11}$$

```
1 from sklearn.preprocessing import MinMaxScaler
2
3 sc = MinMaxScaler(feature_range=(0, 1))
4 training_set_scaled = sc.fit_transform(training_set)
5 test_set = sc.transform(test_set)
```

数据标注

为了实现股票预测，需要对训练用的数据进行标注。
GRU 是根据过去预测未来，因此采用前两个月的数据进行对当日开盘价的预测。
取出后 200 日的数据作为测试数据，前 3832 日数据作为训练数据。
使用 Python 进行数据标注，并保存为 txt 文件，方便在 MATLAB 中进行读取调用。
标注核心代码如下：

```python
import pandas as pd

test_num=200
day=60

zhongshihua = pd.read_csv('./SH600028.csv')
training_set = zhongshihua.iloc[0:len(zhongshihua) - test_num, 2:3].values
test_set = zhongshihua.iloc[len(zhongshihua) - test_num:, 2:3].values

for i in range(day, len(training_set_scaled)):
    x_train.append(training_set_scaled[i - day:i, 0])
    y_train.append(training_set_scaled[i, 0])
```

股市预测的 Python 实现

先在 Python 中调用 tensorflow 框架进行本项目的实现，验证其可行性。

图: 股市预测网络结构

股市预测的 Python 实现

核心代码如下（仅展示模型部分）：

```python
import tensorflow as tf
from tensorflow.keras.layers import Dropout, Dense, GRU

model = tf.keras.Sequential([
    GRU(512, return_sequences=True),
    Dropout(0.2),
    GRU(1024),
    Dropout(0.2),
    Dense(1)
    ])
```

股市预测的 Python 实现

第一层 GRU：512 个单元，每次返回 h^t 参数；令其中 20% 的单元休眠；第二层 GRU：1024 个单元，仅最后一次返回 h^t 参数；令其中 20% 的单元休眠；最后进行全链接输出。在 epochs=100，batch size=32 的训练条件下，预测结果如图5：

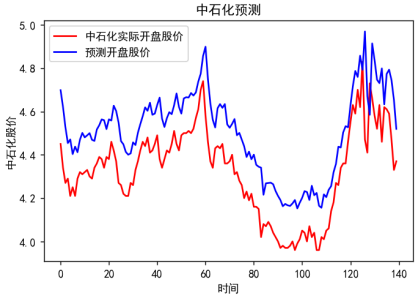

图: 预测结果

目录

深度学习工具箱

深度学习工具箱提供了一个用于通过算法、预训练模型和 App 来设计和实现深度神经网络的框架。在深度学习工具箱中可以使用卷积神经网络（ConvNet、CNN）和长短期记忆 (LSTM) 网络对图像、时序和文本数据执行分类和回归。可以使用自动微分、自定义训练循环和共享权重来构建网络架构，如生成对抗网络 (GAN) 和孪生网络。使用深度网络设计器，能够以图形方式设计、分析和训练网络。试验管理器可管理多个深度学习试验，跟踪训练参数，分析结果，并比较不同试验的代码。可以可视化层激活，并以图形方式监控训练进度。

在 MATLAB 中搭建 GRU 神经网络

在深度学习工具箱中，可以快速搭建神经网络

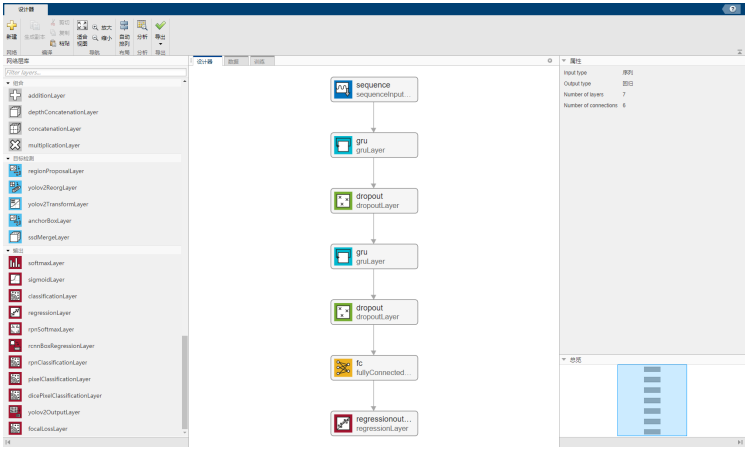

在 MATLAB 中搭建 GRU 神经网络

通过深度学习工具箱，我们可以快速导出神经网络模型，得到结果如图7所示：

图: 使用深度学习工具箱创建深度学习网络架构

在 MATLAB 中搭建 GRU 神经网络

在 Matlab 中，程序核心代码如下：
网络架构部分：

```
function layers=get_gru_net(wd)
numFeatures=wd;
numResponses=1;
numHiddenUnits=512;

layers=[sequenceInputLayer(numFeatures)
    gruLayer(numHiddenUnits)
    dropoutLayer(0.2)
    gruLayer(2*numHiddenUnits)
    dropoutLayer(0.2)
    fullyConnectedLayer(numResponses)
    regressionLayer];
end
```

在 MATLAB 中搭建 GRU 神经网络

在 Matlab 中，程序核心代码如下：
模型超参数选项设置部分：

```
layers=get_gru_net(wd);
options=trainingOptions('adam',...
    'MaxEpochs',100,...
    'GradientThreshold',1,...
    'InitialLearnRate',0.001, ...
    'LearnRateSchedule','piecewise',...
    'LearnRateDropPeriod',125,...
    'LearnRateDropFactor',0.2,...
    'Verbose',0,...
    'Plots','training-progress');
```

喂入数据并训练

在 Matlab 中，使用函数 *trainNetwork* 将数据喂入神经网络并训练。训练过程如图8所示：

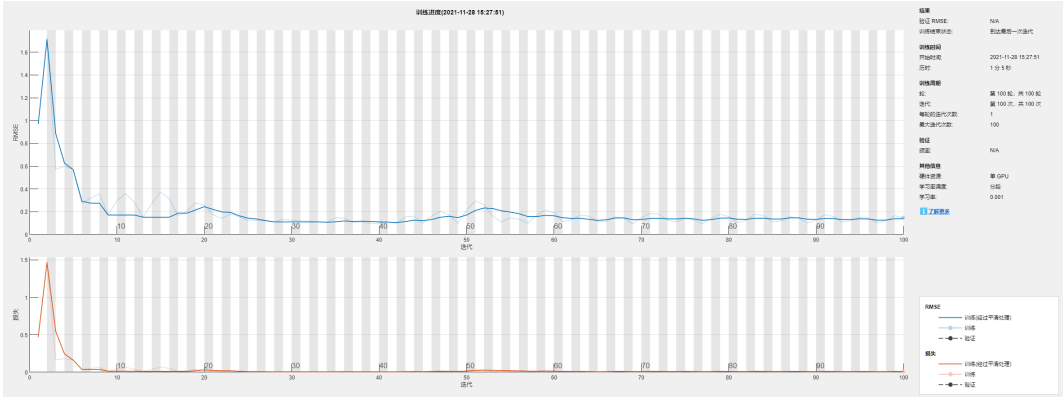

图: 训练进度展示

喂入数据并训练

使用函数 *predict* 调用训练好的模型进行预测。此神经网络预测结果如图9所示：

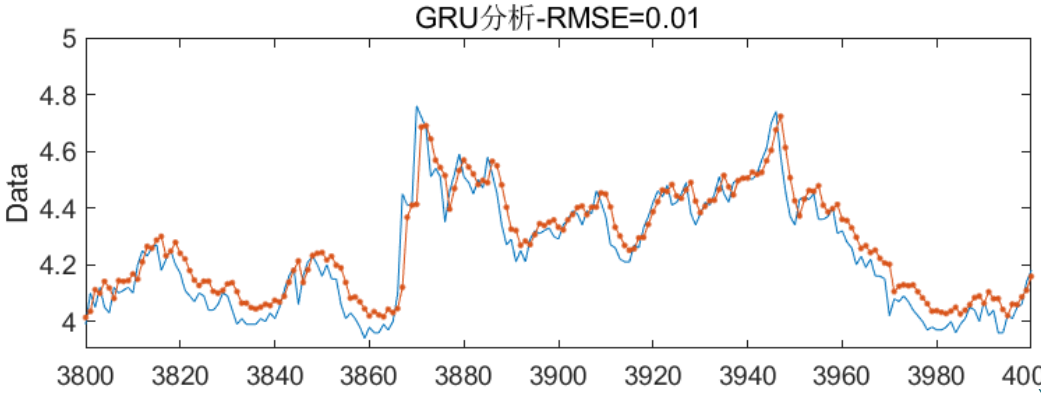

图: GRU 预测结果：图中橘红色曲线为预测数值，蓝色为实际数值

目录

效果评判

后续测试模型中，我们采用茅台 2005 年 1 月 1 日到 2021 年 3 月 20 日的开盘股价作为训练集，为了节省时间，规定每一种模型均跑 100Epoch。
我们使用如下指标进行模型效果评判：

- 计算茅台在 2021 年 3 月 30 日到 2021 年 10 月 16 日，共计 200 日的开盘股价预测数据，并与此 200 日的实际开盘股价计算确定系数。
  确定系数计算公式如下：

$$r(X, Y) = \frac{\mathtt{Cov}(X, Y)}{\sqrt{\mathtt{Var}[X]\mathtt{Var}[Y]}} \tag{12}$$

  式中，$\mathtt{Cov}(X, Y)$ 为 X 与 Y 的协方差，$\mathtt{Var}[X]$ 为 X 的方差，$\mathtt{Var}[Y]$ 为 Y 的方差。
- 计算模型计算速度，测试数据为：茅台在 2021 年 3 月 30 日到 2021 年 10 月 16 日的股价预测数据。计算速度测试中，时间计算单位为 ms，一共跑 100 次，取平均值。

效果评判

接上

- 测试设备为联想拯救者 R9000P（5800H+64G 内存 +RTX3070-8G）
- 综合评判公式：

$$s = \frac{100r}{T} \tag{13}$$

更改模型

在 3.3 中，我们得到了粗略的结果，如图5，其模型如图4。从结果中可以看出，虽然预测所得的结果趋势大致与实际情况近似，但其偏差还是较大。因此，在这一节中，我们更改了模型。其中更改的方向如下：

1. 增减模型层数
2. 调整 Dropout 单元的数量和 Dropout 的数值
3. 调整 GRU 内神经元个数
4. 在 GRU 中使用 softsign 替换 tanh

更改模型

我们据此作出了 10 个新的模型，如表1所示。

表: 10 种调参模型

序号	模型结构	备注
1	GRU(20)→Dropout(0.2)→GRU(20)→Dropout(0.2)→Dense	
2	GRU(20)→Dropout(0.2)→GRU(20)→GRU(20)→Dropout(0.2)→Dense	
3	GRU(40)→Dropout(0.2)→GRU(80)→Dropout(0.2)→Dense	
4	GRU(20)→Dropout(0.5)→GRU(20)→Dropout(0.5)→Dense	
5	GRU(80)→Dropout(0.2)→GRU(160)→Dropout(0.2)→Dense	
6	GRU(20)→GRU(20)→Dropout(0.2)→Dense	
7	GRU(20)→Dropout(0.2)→GRU(20)→Dropout(0.2)→Dense	输出使用 softsign
8	GRU(20)→Dropout(0.7)→GRU(20)→Dropout(0.7)→Dense	
9	GRU(20)→Dropout(0.2)→GRU(20)→Dropout(0.2)→GRU(20)→Dropout(0.2)→Dense	
10	GRU(20)→Dropout(0.2)→GRU(20)→GRU(20)→GRU(20)→Dropout(0.2)→Dense	

更改模型

下面进行模型效果评判，结果如表2：

表: 10 种调参模型的模型效果评判

序号	r	T / ms	s
1	0.9342	58.4025	1.5996
2	0.9354	69.2492	1.3507
3	0.9376	61.2784	1.5301
4	0.9109	61.6864	1.4767
5	0.9382	66.7216	1.4061
6	0.9383	62.9502	1.4905
7	0.5082	257.0746	0.1977
8	0.8806	63.6268	1.3839
9	0.9350	67.8759	1.3776
10	0.9357	79.8768	1.1715

每个 GRU 单元中偏置 b 初始化为 1

此处将所有偏置 b 初始化为 1，模型代码更改为：

```
function layers=get_gru_net(wd)
    numFeatures=wd;
    numResponses=1;
    numHiddenUnits=20;

    layers=[sequenceInputLayer(numFeatures)
    gruLayer(numHiddenUnits,"BiasInitializer","ones")
    dropoutLayer(0.2)
    gruLayer(numHiddenUnits,"BiasInitializer","ones")
    dropoutLayer(0.2)
    fullyConnectedLayer(numResponses)
    regressionLayer];
end
```

评判模型效果，结果如下：$T = 60.573ms,\ r = 0.93623,\ s = \dfrac{100r}{T} = 1.54562$。综合效果不如原本模型，但其训练收敛速度较原本模型有较大提升（loss 收敛至 3×10^{-4} 只需要 40 轮）。

全链接层使用 Highway Network 代替

Highway Network 的灵感来自“解决 RNN 的问题，提出的 LSTM 结构”也就是加入“门”结构。
对于一般网络，其输出可以用如下公式表示：

$$y = H(x, W^H) \tag{14}$$

而在 Highway Network 中，我们定义一个新网络 T，此时输出化为：

$$y = H(x, W^H) \cdot T(x, W^T) + x \cdot (1 - T(x, W^T)) \tag{15}$$

全链接层使用 Highway Network 代替

此时不难发现，对于特殊的 T 值，该输出有如式16的表现：

$$y = \begin{cases} x & T = 0 \\ H \quad (x, W^H) & T = 1 \end{cases} \tag{16}$$

若假设所有的门 T 的均值为 0.5 的话，就是把所有的原始信息一半激活，一半不变直接输入下一层，这样一来则保留了很多信息。同时反向传播的时候，可以让更多的（梯度）信息直接回流到输入，而不需要经过一个非线性转化。

由于笔者没有找到 Matlab 中如何自定义网络，因此此部分在 Python 中使用 tensorflow 实现。

全链接层使用 Highway Network 代替

使用 tensorflow 定义 Highway 单元，其代码如下：

```
1  def highway(x, size, activation, carry_bias=-1.0):
2      W_T = tf.Variable(tf.truncated_normal([size, size], stddev=0.1), name="
           weight_transform")
3      b_T = tf.Variable(tf.constant(carry_bias, shape=[size]), name="bias_transform")
4
5      W = tf.Variable(tf.truncated_normal([size, size], stddev=0.1), name="weight")
6      b = tf.Variable(tf.constant(0.1, shape=[size]), name="bias")
7
8      T = tf.sigmoid(tf.matmul(x, W_T) + b_T, name="transform_gate")
9      H = activation(tf.matmul(x, W) + b, name="activation")
10     C = tf.sub(1.0, T, name="carry_gate")
11
12     y = tf.add(tf.mul(H, T), tf.mul(x, C), "y")
13     return y
```

全链接层使用 Highway Network 代替

更改后的神经网络架构为：GRU(20)→Dropout(0.2)→GRU(20)→Dropout(0.2)→Highway 。此时对此模型进行评估可以得到如下结果：

$$T = 50.387ms,\ r = 0.93382,\ s = \frac{100r}{T} = 1.8536$$

相较于原本模型：$T = 58.402ms,\ r = 0.93418,\ s = \frac{100r}{T} = 1.5996$ 有较大幅度的提升。

结果

由于 Matlab 中无法定义 highway 网络，因此 Matlab 使用结果 3.4.3 中模型得出结果。结果如图10所示。

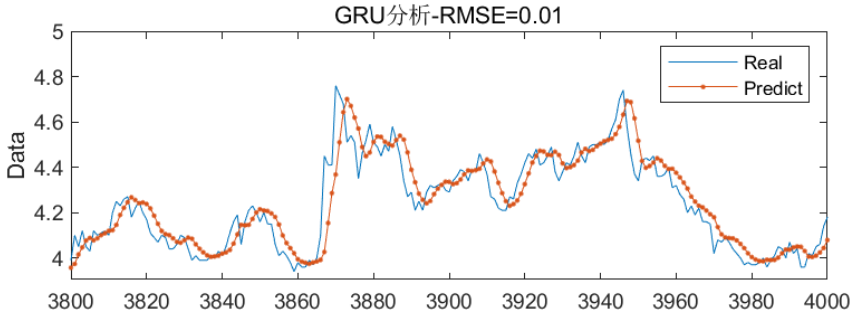

图: MATLAB 中使用 3.4.3 中模型得出结果

结果

在 Python 中，把全链接层换为 Highway 层，得出结果如图11所示。

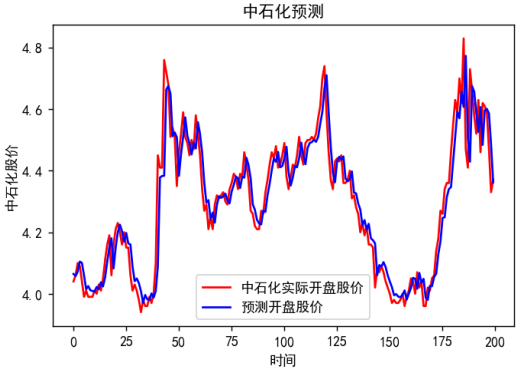

图: Python 中使用 3.4.4 模型得出的结果

目录

K 线图的画法

K 线图源于日本, 被当时日本米市的商人用来记录米市的行情与价格波动, 后因其细腻独到的标画方式而被引入到股市及期货市场。下面来实现茅台预测日 K 线的描绘。

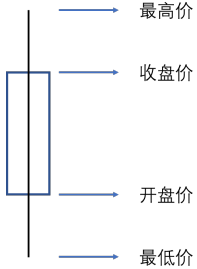

图: K 线图画法

K 线图的画法

日 K 线有如下特点：

1. 日 K 线为股票当日的开盘价、最高价、最低价、收盘价情况
2. 阳线为红色柱体，表示股票上涨情况
3. 阴线为绿色柱体，表示股票下跌情况

K 线数据的准备

K 线数据需要：

1. 开盘价
2. 最高价
3. 最低价
4. 收盘价

使用上一节中的模型对此 4 组数据进行预测并保存到 Xlsx 中，方便在绘制的时候调用。

Matlab 中 K 线的实现

Matlab 中有 candle.m 函数可以实现蜡烛图的绘制，但其结果如下：

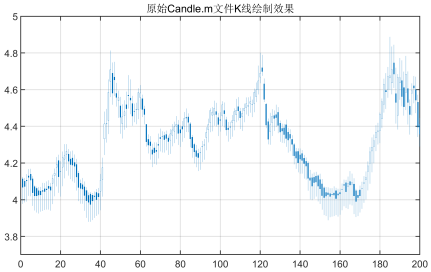

图: 原始 Candle.m 文件 K 线绘制效果

虽然已经有了大体的框架，但与我们常用的 K 线图还是有些许不同，因此需要对脚本进行修改，加入颜色，使其更加直观。

结果

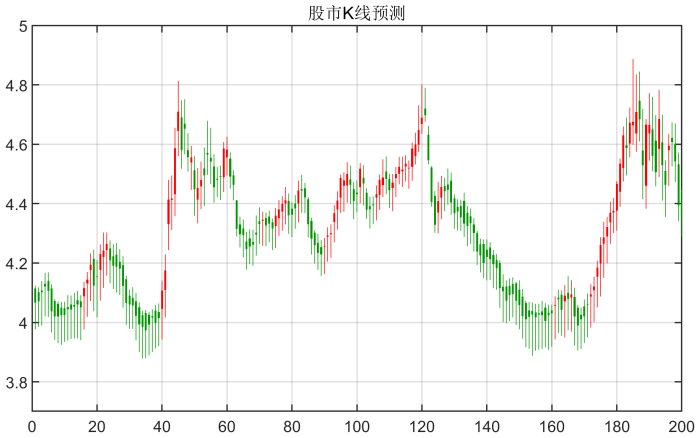

图: 股市 K 线预测

感谢聆听